

TRAITEMENT ET ANALYSE DES DÉBATS PARLEMENTAIRES À LA CHAMBRE DES DÉPUTÉS (1881-1899)

Problèmes, défis et solutions

Aurélien Pellet¹ et Marie Puren²

10 novembre 2022 - Res(t)ituer les adresses des almanachs et annuaires commerciaux parisiens du XIXe siècle. Un corpus de localisations urbaines à grande échelle. 2e Journée de l'atelier SoDUCo-BnF

¹Epitech ²LRE, EPITA

LES DÉBATS PARLEMENTAIRES DURANT LA TROISIÈME RÉPUBLIQUE

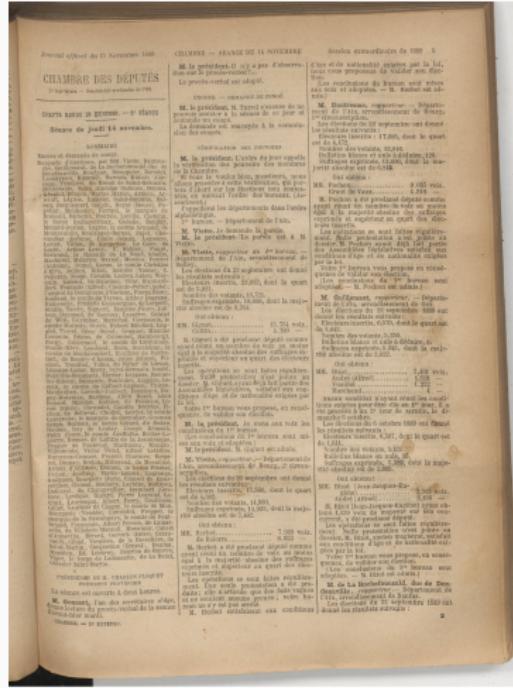


Figure – Séance parlementaire du 14 novembre 1889

- Projet AGODA : Analyse sémantique et Graphes relationnels pour l’Ouverture et l’étude des Débats à l’Assemblée nationale
- Débats à la Chambre des députés (chambre basse du parlement) transcrits en détail dans le **Journal officiel de la République française**. **Débats parlementaires (1881-1940)**
- Disponible en ligne via **Gallica** (bibliothèque numérique de la Bibliothèque nationale de France)
- 15 législatures entre 1881 et 1940 / 10-12.000 images par législature

OBJECTIFS

- Créer une plateforme de consultation
- Produire des données textuelles structurées et sémantiquement enrichies à partir de ces débats numérisés
- Contribuer à la conception d'un workflow adapté à la préparation, à la publication et à l'analyse de grands corpus de documents historiques

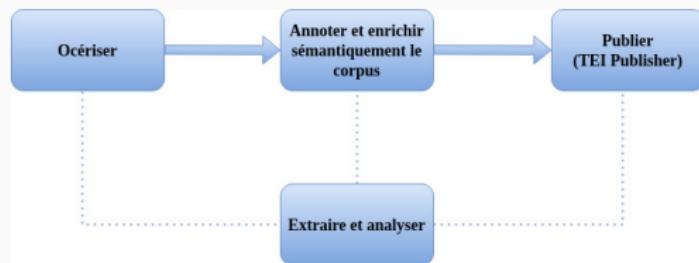


Figure – Les étapes de la chaîne de traitement

OCÉRISER LES DÉBATS

LE CAS DES DÉBATS PARLEMENTAIRES

- Récupération des textes océrisés via [API Document](#) de Gallica => qualité inégale de l'OCR
- Erreurs dues à :
 - qualité du document : tâches et surimpression
 - la **courbure de la page** au niveau de la reliure

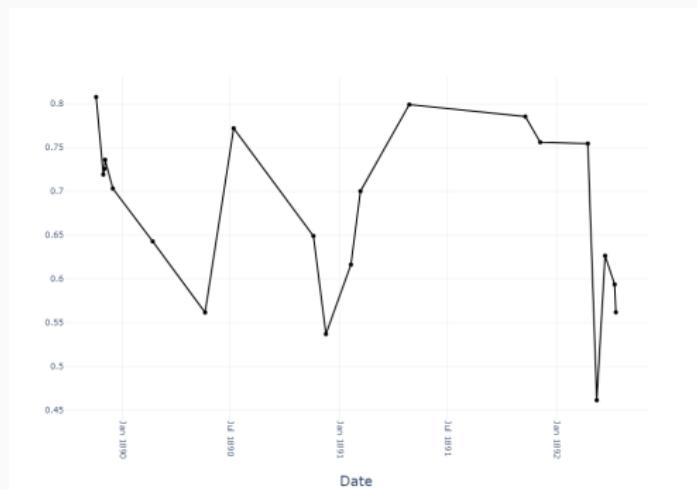


Figure – Evaluation de la qualité de l'OCR fourni par Gallica

EFFET DE LA COURBURE SUR LES RÉSULTATS DE L'OCR

pour les appliquer à son gré ? Assurez-nous. Si d'ailleurs l'administration n'en trouve pas, au pif aller, une toute aussi prétexte pour faire ce qu'elle veut, alors bientôt le texte l'autorisant à imposer une devance de 25 centimes par hectare, personnes qui prennent des permis pour recherche de gisements surférés dans le territoire contesté de l'Awa, si ce territoire n'est pas en sa possession, comme je suppose, comment se fait-il qu'elle impose 20 centimes aux uns, elle impose 25 centimes aux autres ?

Voilà la question.

« Est-ce une inconséquence de sa part ou bien c'est qu'en vertu d'un vote de l'assemblée locale, souveraine en matière de taxe ? Je vous dirai tout de suite qu'il n'aït souvenance d'aucune délibération de cette assemblée locale pour me permettre qu'à un dessous de cartes. Mon devoir de seiller général est de rechercher la clôture et de la dire tout entière quand je l'avoir trouvée. »

« Ensuite bien ceci, messieurs... »
« Eh bien, messieurs, je vous dirai honnêtement que si cette redevance a été imposée, c'est qu'on a, retirer aux petites bourses la faculté d'une concession à l'Awa; c'est qu'on a

pour les appliquer à son gré ? Assurez.

non. Si d'ailleurs l'administration fût trouver, au pif aller, un texte (1011) eu puisse faire état, voudra-t-elle dire le texte l'autorisant à imposer une devance de 25 centimes par hectare, personnes qui prennent des permis Pour la recherche de gisements surférés à tel territoire contesté de l'Awa ? Si ce territoire

n'est pas en sa possession, cornes le suppose, comment se fait-il qu'il Wjs3j 20 centimes aux uns, elle impose 20 centimes aux autres ? » Voilà la question, à

« Est-ce une inconséquence de sa part ou bien a-t-elle agi en vertu d'un vote de l'assemblée locale, souveraine en OlallieC de taxe ? Je vous dirai tout de suite Il n'aït souvenance d'aucune délibératiIl'V ce genre, ce qui me porte à penser à un dessous de cartes. Mon devoir seiller général est de rechercher la clôture et de la dire tout entière quand Je l'avoir trouvée. »

Ecoutez bien ceci, messieurs. « Eh bien, messieurs, je vous dirai de bonnement que si cette redevance 25 centimes a été imposée, c'est qu'on a, retirer aux petites bourses la faculté d'une concession à l'Awa; c'est qu'on a

Figure – 20
octobre
1890
(p.1718)

Figure – Résultat de l'OCR

Décision de ré-océriser le corpus

TRAITER LES IMAGES

Améliorer la qualité de l'image avec une méthode de “dewarping” => résultats peu probants

- Gérer la courbure des pages avec le dewarping?
- Utiliser des outils plus avancés?



(a) Image d'origine



(b) Image "dewarpée"

Figure – Dewarping : pas adapté à nos documents

OUTIL DE NETTOYAGE - ANR SODUCO



(a) Image d'origine



Figure – Exemple d'image nettoyée

OUTIL OCR ET NER - ANR SODUCO

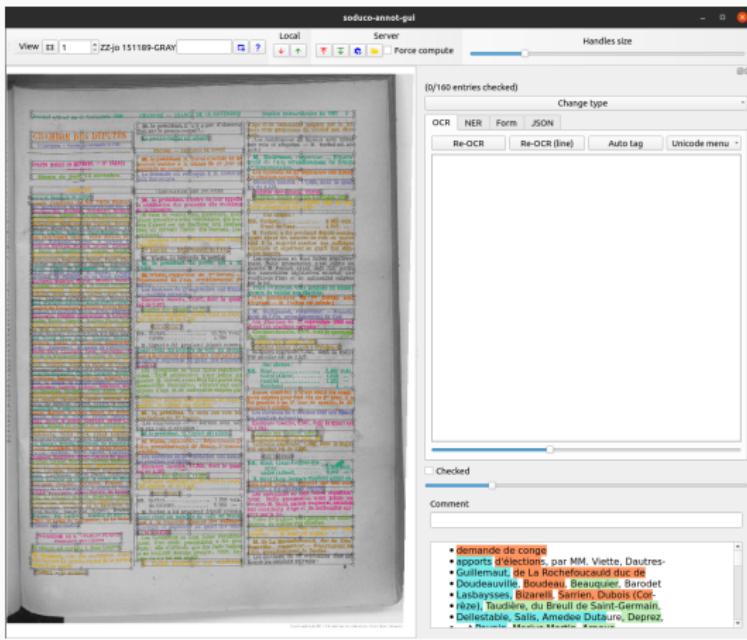


Figure – Démonstration de l'outil sur une page de débat parlementaire

OUTIL OCR ET NER - ANR SODUCO



(a) OCR



(b) NER

Figure – Zones d'OCR et de NER

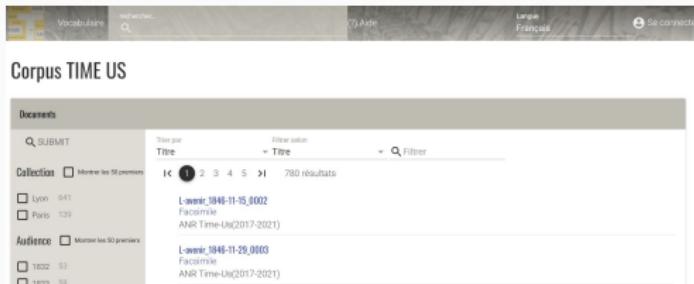
AMÉLIORER LA COURBURE

- Problèmes de reconnaissance de la structure hiérarchique à cause de la courbure
- Objectif n°1 : faire disparaître au maximum cette courbure
- Développement et traitement d'images en C++

Demande de financement dans le cadre de Biblissima +

ANNOTER LES DÉBATS EN XML-TEI

PUBLIER UN CORPUS ÉDITORIALISÉ



(a) Interface de recherche



(b) Affichage d'un document

Figure – Corpus du projet ANR TIME-US publié avec TEI Publisher

CORPS D'UN DÉBAT ENCODÉ EN XML-TEI

```
<div type="part" corresp="#rapportelections">
    <head>SUITE DE LA VÉRIFICATION DES POUVOIRS</head>
    <u who="#pers_ID" xml:id="CR_1889-11-26_u23" ana="#chair">
        <seg xml:id="CR_1889-11-26_u23.1"><persName ref="#pers_ID">M. le <roleName ref="#pers_ID">président</roleName></persName>. L'ordre du jour appelle la suite de la vérification des pouvoirs.</seg>
        <seg xml:id="CR_1889-11-26_u23.2"><persName ref="#pers_ID">M. Reybert</persName> a la parole pour donner lecture d'un rapport sur une élection non contestée.</seg>
    </u>

    <u who="#pers_ID" xml:id="CR_1889-11-26_u24" ana="#rapporteur">
        <!-- Lecture d'un rapport -->
        <quote>
            <seg xml:id="CR_1889-11-26_u24.1"><persName ref="#pers_ID">M. Reybert, <roleName ref="#pers_ID">rapporteur</roleName></persName>.
            -<placeName ref="#lieu_ID">Département de la Corrèze, arrondissement de Tulle, <num>1</num> circonscription</placeName>.</seg>
            <seg xml:id="CR_1889-11-26_u24.2">Les élections du <date when="1889-09-22">22 septembre</date> ont donné les résultats suivants :</seg>
            <seg xml:id="CR_1889-11-26_u24.3">Electeurs inscrits, <num>17,950</num>, dont le quart est de <num>4,263</num>.</seg>
            <seg xml:id="CR_1889-11-26_u24.4">Nombre des votants, <num>12,322</num>.</seg>
            <seg xml:id="CR_1889-11-26_u24.5">Bulletins blancs et nuls, à déduire, <num>133</num>.</seg>
            <seg xml:id="CR_1889-11-26_u24.6">Suffrages exprimés, <num>12,189</num>.</seg>
            <seg xml:id="CR_1889-11-26_u24.7">Ont obtenu : NM. <persName ref="#pers_ID">Borie, <roleName ref="#pers_ID">député sortant</roleName></persName>... <num>7,508</num> voix.</seg>
            <seg xml:id="CR_1889-11-26_u24.8"><persName ref="#pers_ID">Vachal, <roleName ref="#pers_ID">ancien député</roleName></persName>... <num>4,748</num>.</seg>
            <seg xml:id="CR_1889-11-26_u24.9"><persName ref="#pers_ID">M. Borie</persName> a été proclamé député comme ayant réuni un nombre de voix au moins égal à la majorité absolue des suffrages</seg>
        </quote>
    </u>

    <floatingText><body><div><pb n="176"/></div></body></floatingText>

    <!-- [...] -->
</div>
```

Figure – Encodage - Séance parlementaire du 26 novembre 1889 (extrait)

STRUCTURE GÉNÉRALE DES FICHIERS XML TEI

```
<teiCorpus xmlns="http://www.tei-c.org/ns/1.0" xml:id="FR_3R_5L" xml:lang="fr">  
  <!-- Méta données du corpus (non développées) -->  
  <teiHeader>  
    <fileDesc>  
      <titleSt>  
        <title></title>  
      </titleSt>  
      <publicationStmt>  
        <p></p>  
      </publicationStmt>  
      <sourceDesc>  
        <p></p>  
      </sourceDesc>  
    </fileDesc>  
  </teiHeader>  
  
  <!-- Données liées et informations contextuelles -->  
  <standOff>  
    <listPerson>  
      <person></person>  
    </listPerson>  
  
    <listOrg>  
      <org></org>  
    </listOrg>  
  
    <listPlace>  
      <place></place>  
    </listPlace>  
  </standOff>  
  
  <!-- Stockage du composant correspondant à la séance du 26 novembre 1889 -->  
  <x:include xmlns:xl="http://www.w3.org/2001/XInclude" href="FR_3R_5L_1889-11-26.xml"/>  
  
  <!-- Stockage des autres composants du corpus de façon identique -->  
  <!-- ... -->  
  </teiCorpus>
```

(a) Structure générale d'un fichier corpus

```
<TEI xmlns="http://www.tei-c.org/ns/1.0" xml:id="FR_3R_5L_1889-11-26" xml:lang="fr">  
  <!-- Méta données du composant (non développées) -->  
  <teiHeader>  
    <fileDesc>  
      <titleSt>  
        <title></title>  
      </titleSt>  
      <publicationStmt>  
        <p></p>  
      </publicationStmt>  
      <sourceDesc>  
        <p></p>  
      </sourceDesc>  
    </fileDesc>  
  </teiHeader>  
  
  <text>  
    <!-- Transcription du compte rendu -->  
    <body>  
      <div></div>  
    </body>  
    <!-- Annexes du compte rendu -->  
    <back></back>  
  </text>  
</TEI>
```

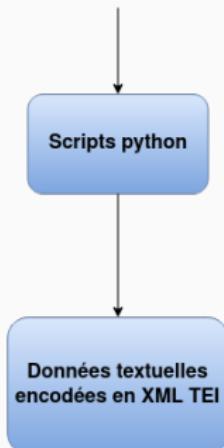
(b) Structure générale d'un fichier composant

Figure – Encodages - Structure générale des fichiers corpus et composant

APPLIQUER L'ENCODAGE : AUTOMATISATION

```
v 19:
    activities: []
    addresses: []
  ▼ box:
    0: 220.12998972250773
    1: 202.1299897225077
    2: 561.0527107504491
    3: 00.4410437486525
  checked: true
  comment: "seg"
  id: 276
  ▼ ner_xml:
    <PER>M. Borie</PER> a <ACT>déjà fait partie des Assemblées\ulégitimatives et satisfait aux conditions d</ACT>'<ACT>\âge\ul2029et de
    nationalité</ACT> exigées par la loi.\ul2029L'élection de la 2e circonscription de'
    origin: "computer"
    parent: 201
  ▼ persons:
    0: "M. Borie"
  ▼ text_ocr:
    "M. Borie a déjà fait partie des Assemblées\ulégitimatives et satisfait aux conditions d'\âge\ulnet de nationalité exigées par la loi."
    type: "ENTRY"
```

Données textuelles au format JSON



DE JSON VERS XML-TEI

- Données textuelles dans les fichiers JSON = valeurs des clés "text_ocr"
- Clés contenues dans des objets qui correspondent à la segmentation au niveau paragraphe
- Appliquer des règles de transformation sur les valeurs des clés "text_ocr"

A LA RECHERCHE DE "FEATURES"

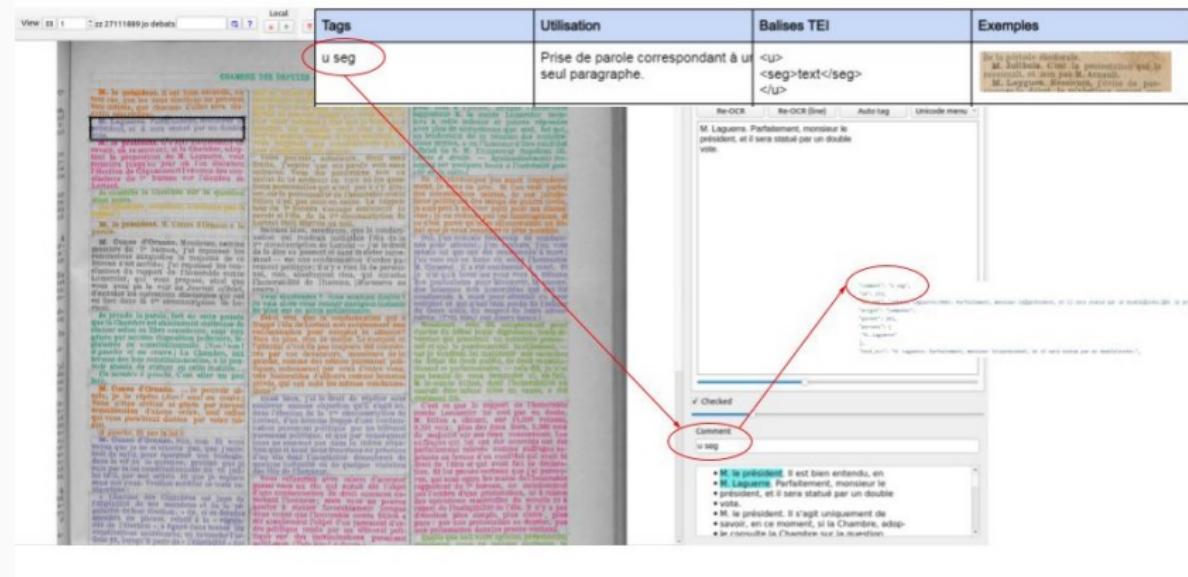


Figure – Du guide d'annotation à l'export JSON

RÉSULTATS

```
{  
    "activities": [],  
    "addresses": [],  
    "box": [  
        57.6110701150507,  
        111.0  
        560.3883298849495,  
        58.0776597698992  
    ],  
    "checked": true,  
    "comment": "u seg",  
    "id": 985,  
    "key": [  
        0,  
        1735  
    ],  
    "ner_xml": "<PER>M. Paul Déroulede</PER>. Je demande la pa-<O>x2029-Tole",  
    "origin": "computer",  
    "parent": 269,  
    "persons": [  
        "M. Paul Déroulede"  
    ],  
    "text_ocr": "M. Paul Déroulede. Je demande la pa-\nrole.",  
    "type": "ENTRY"  
}
```

(a) Fichier JSON avec une prise de parole

```
def add_utterance(data):  
    ...  
    Ajout de l'élément TEI "u" pour chaque boîte étiquetée "u" ou "u-beginning" et "u-end"  
    :param data: dictionnaire contenant l'ensemble des données issues des JSON  
    ...  
    for i in range(len(data)):  
        if re.search(r"^(u|u-b|u-e)", data[i]["comment"]):  
            if re.search(r"^(u|u-b)\b", data[i]["comment"]):  
                data[i][("text_ocr")] = "".join([{"<u>", data[i][("text_ocr")], '</u>'}])  
            elif re.search(r"u-beginning", data[i]["comment"]):  
                data[i][("text_ocr")] = "".join(['<u>', data[i][("text_ocr")]])  
            elif re.search(r"u-end", data[i]["comment"]):  
                data[i][("text_ocr")] = "".join([data[i][("text_ocr")], '</u>'])  
            else:  
                pass  
    return data
```

(b) Fonction add_utterance

<u><seg>M. Paul Déroulede. Je demande la parole.</seg></u>

(c) Résultat

Figure – Exemple d'application de la fonction add_utterance

CRÉATION DES FICHIERS COMPOSANTS

1. Récupération des données JSON stockées dans une variable "data" sous forme d'un dictionnaire.
2. Gestion de l'encodage des changements de page.
3. Intégration des scripts contenant les règles de transformation dans la chaîne de traitement. Permettent d'encoder les données contenues dans la variable "data".
4. Création de l'élément <teiHeader> contenant les métadonnées :
 - Rédaction d'une partie du <teiHeader> à la main contenant les métadonnées "fixes"
 - Construction de règles permettant de rechercher les métadonnées propres à chaque compte rendu, présentes dans la variable "data", par la suite intégrées au <teiHeader> préalablement établi
5. Création des fichiers XML valides.
6. Nettoyage des fichiers XML (gestion des césures).

CRÉATION DU FICHIER CORPUS

1. Génération du fichier corpus.
2. Intégration des métadonnées.
3. Gestion des <xi :include>.

ANNOTATION SEMI-AUTOMATIQUE ET EXPORT EN XML-TEI

1. Annotation manuelle très consommatrice de temps et non exempte d'erreurs
 - Ajout de manière semi-automatique des étiquettes
 - Permettre aux utilisateurs de réutiliser les étiquettes et de créer leurs propres étiquettes (vocabulaire contrôlé?)
2. Utiliser ces scripts pour proposer un export XML-TEI (outil SODUCO)
 - Ajouter les entités nommées (<persName>, <orgName>, etc.)

Demande de financement dans le cadre de Biblissima +

TOPIC MODELING ET WORD EMBEDDING

DÉCOMPOSITION EN VALEURES SINGULIÈRES

- On observe deux blocs de documents :
 - Mots positivement corrélés à la première composante : martin, paul, jules, léon, vicomte, seine, baron, comte...
 - Mots positivement corrélés à la seconde composante : monsieur, commission, ministre, projet, chambre, président, loi...

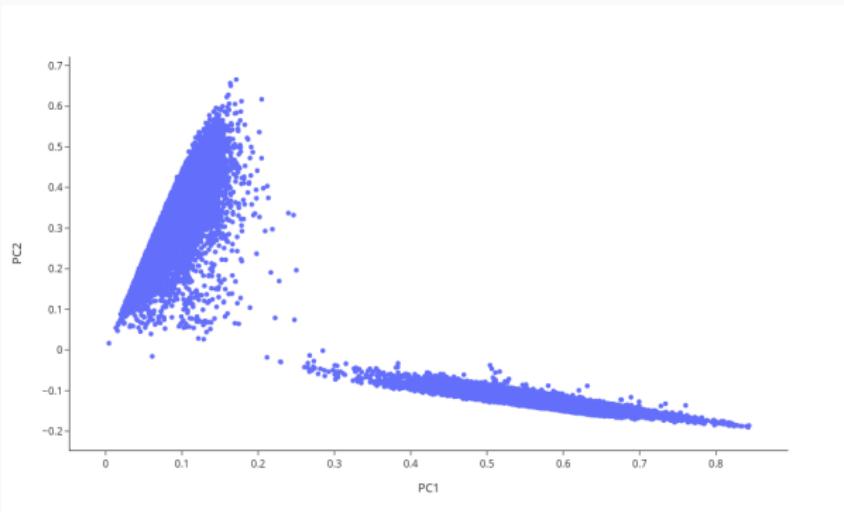


Figure – Décomposition en valeur singulière de la matrice de fréquence (+ tfidf)

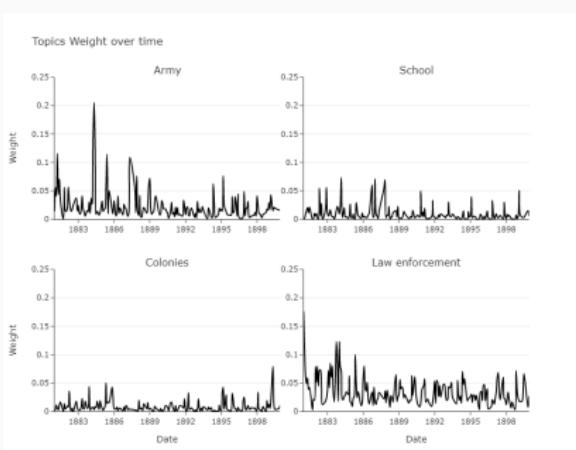
ONT VOTÉ POUR :

MM. Abbatucci. Achard. Agniel. Allain-Targé. Allègre. Allemand. Amat. André (Jules). Andrieux. Anisson-Duperron. Anthoard. Arenberg (prince d'). Ariste (d'). Armez. Arnoult. Arrazat. Audiffred. Aulan (marquis d'). Azémar. Baduel d'Oustrac. Balhaut. Ballue. Bamberger. Bansard des Bois. Barascud. Barbedette. Bardoux. Barodet. Barthe (Marcel). Bastid (Adrien). Baudry-d'Asson (æ). Baury. Beauchamp (de). Beauquier. Beaussire. Bel (François). Belle. Bénazet. Benoist. Berger. Bergerot. Berlet. Bernard. Bernier. Bert (Paul). Bertholon. Bianchi. Bienvenu. Binachon. Bizzarelli. Bizot de Fonteny. Blanc (Louis) (Seine). Blanc (Pierre) (Savoie). Blandin. Blin de Bourdon (vicomte). Bonnaud. Bonnet-Duverdier. Borriglione. Bosc. Bouchet. Boudeville. Boulard (Cher). Boulart (Landes). Bouquet. Bourgeois. Bousquet. Bouteille. Bouthier de Rochefort. Boyer (Ferdinand). Brame (Georges). Bravet. Breay. Bresson. Brice (René). Brierre. Brisson (Henri). Brossard. Bruneau. Buyat. Cadot (Louis). Caduc. Cantagrel. Carnot (Sadi). Casabianca (vicomte de). Casimir-Perier (Aube). Casimir-Perier (Paul) (Seine-Inférieure). Cassezeaux. Castagnède. Caurant. Caze. Ca-

EXPLORER LES DÉBATS AVEC LA MODÉLISATION DE SUJETS

Topic 8	Topic 11	Topic 15
salaire	général	pari
question	commission	télégraphe
gouvernement	régiment	faire
jour	troupe	ingénieur
patron	monsieur	train
chambre	année	ligne
droit	jeune	chambre
syndicat	temps	personnel
délégué	faire	etat
monsieur	corps	administration
travail	soldat	employé
travaux	ministre	poste
ministre	homme	public
grève	loi	travaux
faire	an	service
mineur	guerre	agent
mine	service	ministre
loi	militaire	fer
compagnie	officier	chemin
ouvrier	armée	compagnie

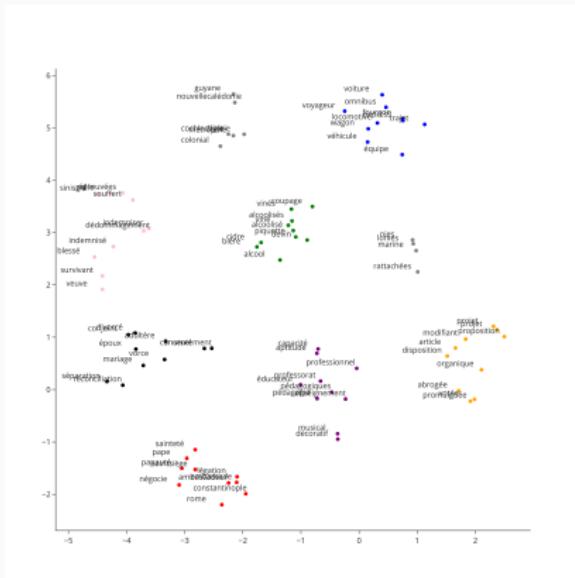
(a) 3 sujets parmi 40 : classe ouvrière (8), armée (11) et infrastructures (15)



(b) Evolution de quatre sujets au cours du temps

Figure – Résultats de la modélisation de sujets

LES PLONGEMENTS DE MOTS : WORD2VEC ET TOP2VEC



(a) Projection t-SNE des centroïdes des vecteurs (word2vec)

Cluster 55	Cluster 68	Cluster 70
victimes	divorce	enveloppes
inondations	époux	timbres
secourir	mariage	poste
éprouves	conjugal	postale
orages	divorces	timbre
sinistres	adultere	recepisses
grele	conjugale	postes
sauveteurs	remarier	postaux
venir	separation	telegraphes
infortunes	indissolubilité	colis
ravages	conjoints	fixe
miseres	mutuel	recouvrements
catastrophe	separations	graphes
evenements	mari	postales
repartition	mariages	taxe
incendies	femme	decide
soulager	conjoint	soit

(b) 3 clusters parmi les 113 obtenus avec top2vec : tempêtes (55), divorce (68) et poste (70)

Figure – Résultats obtenus avec word2vec et top2vec

PROXIMITÉ TOPIC-DOCUMENT

Possibilité de calculer la cosine similarity entre un topic et des documents

QUESTION A M. LE MINISTRE DE L'INTÉRIEUR	
M. le président. La parole est à M. Margaine pour adresser une question à M. le ministre de l'intérieur, qui l'a acceptée.	M. le président. L'ordre du jour appelle la première délibération sur le projet de loi tendant à créer des timbres spéciaux pour la constatation des versements sur les livrets de la caisse d'épargne postale.
M. Margaine. Messieurs, d'accord avec M. le ministre de l'intérieur, je viens lui demander s'il n'entend pas appliquer le secours de 500,000 fr. qu'il a demandé aux quelques départements qui, en dehors des inondations, ont été victimes d'orages, d'incendies ou de sinistres quelconques. (Mouvements divers.)	La parole est à M. le rapporteur.
M. de Châtenay. Il y a un crédit spécial voté pour cela !	M. Barhaut, rapporteur. Messieurs, au nom de la commission du budget, d'accord avec M. le ministre des postes et télégraphes, j'ai l'honneur de demander à la Chambre de vouloir bien prononcer l'urgence sur le projet de loi relatif à la création de timbres spéciaux pour les livrets de la caisse d'épargne postale.
M. le président. La parole est à M. le ministre de l'intérieur.	M. le président. Je consulte la Chambre sur la demande de la déclaration d'urgence. (L'urgence, mise aux voix, est déclarée.)
M. Sarrien, ministre de l'intérieur. Messieurs, le crédit de 500,000 fr. que je demande à la Chambre a uniquement pour objet de secourir les misères résultant des inondations. (Très bien ! très bien !)	M. le président. Personne ne demandant la parole pour la discussion générale, je consulte la Chambre sur la question de savoir si elle entend passer à la lecture des articles.
En ce qui concerne les départements qui ont été éprouvés par des orages ou par la grêle, — si je crois que c'est le cas du département de la Marne, que représente l'honorable M. Margaine... .	
Sur divers bancs. Et des Ardennes ! — Et de l'Aisne ! — Et de la Meuse !	

(a) cos sim = 0.73

(b) cos sim = 0.81

Figure – Résultats obtenus avec word2vec et top2vec

POUR EN SAVOIR PLUS

- Nicolas Bourgeois, Aurélien Pellet, Marie Puren. "Using Topic Generation Model to explore the French Parliamentary Debates during the early Third Republic (1881-1899)". ([hal-03526254v2](#))
- Marie Puren, Nicolas Bourgeois, Aurélien Pellet, Pierre Vernus, Fanny Lebreton. "Between History and Natural Language Processing : Study, Enrichment and Online Publication of French Parliamentary Debates of the Early Third Republic (1881-1899)". ParlaCLARIN III at LREC2022 - Workshop on Creating, Enriching and Using Parliamentary Corpora, Jun 2022, Marseille, France. ([hal-03623351](#))

MERCI POUR VOTRE ATTENTION !



Aurélien Pellet : aurelien.pellet@epitech.eu

Marie Puren : marie.puren@epita.fr

Répertoire Github du projet : <https://github.com/mpuren/agoda>

Mémoire de Fanny Lebreton :

<https://github.com/FannyLbr/Memoire-AGODA-TNAH2022>